

PARECER EDITORIAL

Avaliação técnica sênior

IEEE Access · Visão Computacional · Machine Learning Experimental · Estatística Aplicada

Manuscrito avaliado

Partitioning Protocol Governs Reported Performance in a Single-Setup Soybean Grain Dataset: An Open RGB Pipeline and a Group-Disjoint Benchmark

Arquivo-fonte: artigo1_rgb_en_versao_atual (1).pdf

Escopo probatório: exclusivamente o PDF fornecido; nenhum artefato externo foi presumido como disponível ou indisponível.

DECISÃO SIMULADA

ACCEPT

Tecnicamente sólido, com ajustes editoriais não bloqueadores e verificabilidade externa pendente.

Evidências sustentam as conclusões?	SIM, dentro do escopo declarado
Probabilidade calibrada de aceitação	78%
Confiança nesta revisão	92%
PDF	23 páginas · 12 tabelas · 7 figuras

1. Resumo executivo

O manuscrito apresenta uma avaliação tecnicamente cuidadosa do efeito da unidade de particionamento em um conjunto RGB de grãos de soja. O desenho compara, no mesmo universo de 48.039 instâncias, partições aleatórias por grão e partições disjuntas por fotografia, usa macro F1 como métrica principal, repete dez sementes e explicita a dependência entre as partições. A afirmação central - que a divisão por instância produz desempenho reportado mais alto neste conjunto - é sustentada em direção, magnitude média e consistência. O artigo não transforma a ausência de validação externa, a campanha única, o rótulo em lote ou a dependência entre blocos em conclusões mais fortes do que os dados permitem. A decomposição de variância, a análise por classe, o experimento de isolamento de vazamento e as comparações controladas são apresentadas com ressalvas adequadas. A auditoria numérica não encontrou divergência objetiva entre tabelas, texto, resumo, discussão e conclusão. Permanecem ajustes de precisão no resumo e na conclusão e a necessidade editorial de verificar os artefatos declarados. Nenhum deles, no PDF fornecido, invalida a solidez técnica.

As evidências sustentam as conclusões? **Sim, dentro do escopo in-domain, single-setup e condicional às partições executadas.**

2. Pontos fortes

- O protocolo de particionamento é tratado como objeto científico central, não como detalhe de implementação.
- As duas baterias principais usam o mesmo universo filtrado de 48.039 instâncias e dez sementes pareadas.
- A análise de RQ1 respeita o agrupamento por semente: as seis diferenças arquiteturais são agregadas antes do teste.
- Macro F1, desempenho por classe, dispersão entre sementes e unidade de aquisição são reportados em conjunto.
- Friedman-Nemenyi é explicitamente rebaixado a resumo descritivo, porque os blocos não são datasets independentes.
- O experimento de isolamento mantém teste, tamanho de treino e proporções de classe fixos ao injetar proveniência da mesma fotografia.
- As limitações sobre sessão, campanha, ground truth, segmentação, SSIM, prevalência e implantação são literais e reaparecem na conclusão.
- A apresentação gráfica está íntegra: tabelas e figuras são legíveis, sem sobreposição, corte ou rótulos ilegíveis.

3. Críticos

Nenhum apontamento CRÍTICO sobreviveu à releitura final.

A decomposição de variância está consistente entre Resultados e Conclusão (23,2%/41,9% no protocolo aleatório; 73,9%/6,2% no agrupado; SST 67,5 para 515,5 p.p.², ou 7,64 vezes). As limitações que poderiam bloquear a aceitação são declaradas e não são ignoradas pelas conclusões.

4. Importantes

11. O resumo ainda chama os cruzamentos de Nemenyi de ‘separations’ sem a qualificação descritiva

Local: Resumo: “The ranking is not consistent: rank agreement is weak ($W = 0.28$), five of six architectures lead at least once, and the surviving Nemenyi separations shift with the class set.”

Problema: O corpo corrige adequadamente a interpretação, mas o resumo pode ser lido isoladamente como inferência post-hoc calibrada. Os dez blocos são partições dependentes do mesmo dataset.

Correção: Substituir por: “The ranking is not consistent: rank agreement is weak ($W = 0.28$), five of six architectures lead at least once, and the architecture pairs exceeding the nominal Nemenyi critical-difference threshold change with the retained class set; these are descriptive crossings over dependent blocks, not population-level post-hoc inferences.”

Recurso exigido: texto; cerca de 10 minutos; nenhum novo experimento.

I2. A disponibilidade e a recomputabilidade declaradas não são verificáveis pelo PDF isolado

Local: Data and Code Availability: “from which the analyses of Section IV [...] can be recomputed”.

Problema: O PDF declara dataset, manifests, predições, matrizes, scripts, releases, commits e DOIs, mas nenhum desses artefatos integra o material fornecido nesta rodada. O estado é indeterminado, não uma falha demonstrada.

Correção: Antes da publicação, abrir os dois DOIs e o release em sessão não autenticada; clonar o commit f918a45 em ambiente limpo; executar scripts/reproduce.py; confirmar a regeneração das Tabelas 5, 7, 9, 10, 11 e 12; publicar inventário, checksums SHA-256 e comando único de reprodução no README.

Recurso exigido: verificação e reanálise dos dados existentes; 1 a 3 horas; nenhum novo treinamento, salvo se a recomposição revelar artefato ausente.

5. Menores e sugestões

M1. Linguagem inferencial residual na conclusão prática

Local: Conclusão: “no statistically detectable difference in macro F1”.

Problema: Mesmo com as ressalvas anteriores, a expressão pode soar como teste populacional válido.

Correção: Substituir por: “the paired macro-F1 contrast was inconclusive across the ten repeated partitions, with its run-to-run interval spanning zero; the post hoc TOST likewise did not establish equivalence.”

Recurso exigido: texto; menos de 15 minutos.

M2. Rótulo ‘95% CI’ ainda aparece no corpo

Local: Seção IV-A: “95% CI [3.94, 7.54]”; a Seção III-H informa que ‘95% CI’ é apenas abreviação de intervalo de variação entre execuções.

Problema: Leitores podem interpretar CI como incerteza populacional, embora o manuscrito negue essa leitura.

Correção: Substituir globalmente ‘95% CI’ por ‘run-to-run 95% interval’ nas passagens descritivas e preservar ‘Fisher 95% CI’ apenas onde o intervalo de Fisher é realmente o estimador pretendido.

Recurso exigido: texto; 15 a 30 minutos.

M3. Metadado do template

Local: Rodapé de todas as páginas: “VOLUME 11, 2023”.

Problema: O ano e o volume não correspondem ao estágio atual e podem parecer metadados editoriais reais.

Correção: Remover volume/ano predefinidos na versão de submissão e deixar esses campos para a editora.

Recurso exigido: formatação; menos de 15 minutos.

M4. A conclusão encurta demais a função do SSIM

Local: Conclusão: “including an SSIM-based module that flags candidate outliers”.

Problema: Os Métodos deixam claro que o módulo apenas encaminha candidatos para revisão humana; a conclusão omite essa etapa.

Correção: Usar: “including an SSIM-based module that flags candidate outliers for expert review”.

Recurso exigido: texto; menos de 5 minutos.

S1. Validação independente do ground truth - opcional, não condição de aceitação

Local: Limitações: “No intra- or inter-grader agreement was measured”.

Problema: Trata-se de limitação inevitável e declarada desta coleta, não de erro do manuscrito; ela impede apenas afirmações fortes sobre concordância com o padrão humano.

Correção: Em trabalho futuro, sortear 400 a 800 grãos estratificados por classe, obter três julgamentos independentes, registrar adjudicação e publicar matriz de concordância por classe.

Recurso exigido: novo experimento humano; aproximadamente 8 a 20 horas de rotulagem mais análise. Sugestão opcional.

6. Reprodutibilidade

- ✓ Hardware, CUDA e cuDNN declarados: RTX 3070 8 GB, CUDA 12.6 e cuDNN 9.10.2.
- ✓ Versões principais declaradas: Python, PyTorch, torchvision, OpenCV, scikit-image, scikit-learn e NumPy.
- ✓ Hiperparâmetros por arquitetura, seeds, receitas, augmentations, checkpoint e parada antecipada são informados.
- ✓ Particionamento por fotografia, algoritmo de bin-packing, proporções e exceções são descritos.
- ✓ A bateria aleatória filtrada e a agrupada operam sobre o mesmo universo de 48.039 instâncias.
- ✓ Métricas, unidade estatística, agregação por semente e limitação dos blocos dependentes são explicitadas.
- ⚠ Dataset, manifests, predições, matrizes e scripts são declarados, mas não foram abertos nesta revisão.
- ⚠ A recomposição das análises centrais parece prevista por scripts/reproduce.py, mas não foi executada a partir do PDF.
- ✗ A triagem SSIM original não pode ser reexecutada identicamente porque as imagens de referência não foram preservadas; a limitação é declarada.
- ✗ Não há medidas de precisão/recall da segmentação ou triagem, nem concordância intra/interavaliador; a limitação é declarada.
- ✗ Não existe teste externo por campanha, sessão, equipamento, operador ou instalação; a conclusão permanece corretamente in-domain.

7. Verificação numérica

7.1 Conferido

- ✓ Tabela 2: soma do conjunto lançado = 48.973; benchmark = 48.039; exclusão = 934; fotografias = 466.
- ✓ Média global: $48.039 / 466 = 103,088$ grãos/fotografia, compatível com 103.
- ✓ Arquivos liberados: $48.973 + 48.432 = 97.405$.
- ✓ Probabilidade para 104 grãos: $0,8^{104} + 2 \times 0,1^{104} = 8,34 \times 10^{-11}$; para 14 grãos = 4,40%, compatível com $\approx 4\%$.
- ✓ Tabela 5, macro F1: médias 93,4817% e 87,7450%; diferença = -5,7367 p.p., compatível com -5,74.
- ✓ Tabela 5, acurácia: médias 97,6850% e 94,8617%; diferença = -2,8233 p.p., compatível com -2,82.
- ✓ Gaps por classe: média dos oito valores = 5,74 p.p.
- ✓ Classes esparsas: $(8,87 + 9,84 + 16,75) / (8 \times 5,74) = 77,22\%$; insetos = 36,48%; mamona = 0,26%.
- ✓ Quatro classes bem amostradas: $(2,54 + 0,11 + 2,43 + 5,26) / 8 = 1,2925$ p.p., compatível com 1,29.
- ✓ Dose de isolamento: $2.548 / 37.804 = 6,740\%$; reprodução: $3,11/6,18 = 50,3\%$ e $1,93/5,67 = 34,0\%$.
- ✓ Tabela 7: retenções $83,53/88,53 = 94,35\%$ e $84,34/87,35 = 96,55\%$.
- ✓ Tabela 8: média dos oito F1 arredondados = 87,7375%, compatível com 87,74%.
- ✓ Tabela 9: média dos seis desvios-padrão de macro F1 = 2,9733 p.p., compatível com 2,97.
- ✓ Nemenyi: $CD = 2,85 \times \sqrt{42/60} = 2,384$; com 20 seeds = 1,686; com 30 = 1,377.
- ✓ Tabela 10: as parcelas somam 100,0%, 100,0% e 100,1% (última diferença apenas por arredondamento).
- ✓ Tabela 10: $32,1/515,5 = 6,23\%$; $37,6/305,2 = 12,32\%$; $18,3/133,9 = 13,67\%$.
- ✓ Crescimento de SST: $515,5/67,5 = 7,637$ vezes, compatível com 'nearly eightfold'; SSA cresce $32,1/28,3 = 1,134$.
- ✓ Tabela 11: amplitude $89,23 - 86,94 = 2,29$ p.p.

- ✓ Tabela 12: +0,61; -0,32; -0,41; +0,52; +0,39; +1,03 são reproduzidos pelas Tabelas 9 e 11.
- ✓ Viés de prevalência: limite $0,055/(0,018+0,055) = 75,34\%$; a 2%, 5%, 8% e 60,6%, as razões são 3,677×, 2,027×, 1,614× e 1,018×.

7.2 Divergente

- ✓ Nenhuma divergência objetiva foi encontrada entre valores repetidos no resumo, tabelas, resultados, discussão e conclusão.

7.3 Não recalculável apenas pelo PDF

- Os dez valores por semente que geram intervalos t, Wilcoxon, rrb e testes de permutação.
- As contagens 57/60 e 60/60 e a afirmação de queda em todos os dez agregados por seed.
- Os intervalos BCa, bootstraps por fotografia e correlações por seed ou classe.
- Os 67-92% por seed da decomposição do gap, 97,4% da variância entre seeds nas classes esparsas e as covariâncias completas.
- Os resultados do experimento de isolamento, replicações fixas, ablação e braço uniforme além dos agregados impressos.
- As células suprimidas da matriz de confusão e os valores por arquitetura no suplemento.
- A auditoria dos 80 pares classe-seed por trecho de frames.
- Integridade, disponibilidade e capacidade real de recomputação dos DOIs, releases e repositório.
- Fluxo PRISMA 172/79 e o inventário das três tabelas suplementares, pois o suplemento não foi fornecido.

7.4 Teste de instâncias das afirmações centrais

Afirmação	Instâncias localizadas	Resultado
Gap de protocolo: 5,74 p.p. macro F1; 2,82 p.p. acurácia	Resumo; Contribuições; IV-A; Tabelas 5/12; Discussão; Conclusão	Consistente em força, universo e unidade por seed
Ranking instável; W=0,28; cinco de seis lideram	Resumo; RQ2/RQ3; Tabelas 6/9; IV-H; Fig. 7; Discussão; Conclusão	Consistente; inferência explicitamente descritiva
77% do gap nas três classes mais esparsas	Resumo; Contribuições; IV-A; Tabela 10; Discussão; Conclusão	Consistente; causalidade interna é negada
Dose 6,7% reproduz um terço a metade do contraste	Resumo; Contribuições; IV-A; Limitações; Conclusão	Consistente; não apresentada como decomposição total
Generalização apenas within-campaign/single-setup	Título; Resumo; Métodos; Limitações; Conclusão	Consistente; sessão externa não é reivindicada

8. Inglês

Trecho original	Motivo	Redação sugerida
surviving Nemenyi separations shift with the class set	'Separations' pode soar inferencial no resumo.	pairs exceeding the nominal Nemenyi critical-difference threshold change with the retained class set; these are descriptive crossings over dependent blocks
no statistically detectable difference in macro F1	Excede a interpretação condicional dos blocos repetidos.	the paired macro-F1 contrast was inconclusive across the ten repeated partitions, with its run-to-run interval spanning zero
including an SSIM-based module that flags candidate outliers	A conclusão omite que há adjudicação humana.	including an SSIM-based module that flags candidate outliers for expert review

9. Risco editorial

Risco	Ponto provável de revisão	Leitura calibrada
ALTO	Artefatos externos não abrem ou não recompõem os números centrais	Converteria integridade verificável de indeterminada em não atendida
MÉDIO	Friedman-Nemenyi ainda percebido como inferência apesar das ressalvas	Mitigado pelo enquadramento descritivo; corrigir o resumo reduz o risco
MÉDIO	Ausência de campanha/sessão externa	Limitação declarada; não bloqueia o escopo single-setup
MÉDIO	Ground truth sem concordância entre avaliadores	Limitação declarada; restringe validade do rótulo, não invalida a comparação interna
BAIXO	Template 2023 e terminologia residual	Correção editorial direta

10. Parecer final

DECISÃO SIMULADA: ACCEPT

O manuscrito satisfaz o limiar de solidez técnica do IEEE Access no material fornecido. As conclusões são condicionais, quantitativamente consistentes e compatíveis com as limitações declaradas. Os ajustes restantes melhoram precisão e verificabilidade, mas não exigem novo experimento para sustentar a decisão.

Critérios IEEE Access

- Solidez técnica:** Atendido. Métodos válidos; dependência, unidade estatística e confundidores são tratados explicitamente.
- Sustentação das conclusões:** Atendido. Todas as afirmações centrais permanecem consistentes entre resumo, resultados, discussão e conclusão.
- Contribuição:** Atendido. Quantifica um problema conhecido em um domínio específico e oferece benchmark, pipeline e diagnóstico por classe.
- Apresentação:** Atendido com ajustes menores. Inglês compreensível; figuras e tabelas legíveis.
- Referências:** Atendido no PDF. Bibliografia pertinente e atualizada até 2026; protocolo suplementar não foi auditado.
- Escopo:** Atendido. Visão computacional, avaliação de ML e aplicações agrícolas estão no escopo.
- Integridade verificável:** Indeterminada nesta rodada. Os artefatos são declarados com identificadores específicos, mas não foram abertos.

Condições que inverteriam esta decisão para REJECT

- DOIs, release ou commit indisponíveis, ou scripts incapazes de recompor as análises centrais declaradas.
- Descoberta, nos dados por execução, de incompatibilidade material com 5,74/2,82 p.p., 57/60, 77% ou a decomposição de variância.
- Reintrodução de linguagem populacional/causal que ignore a dependência dos blocos, a campanha única ou a impossibilidade de separar sessão, treino e atalho visual.

Probabilidade e confiança

Probabilidade calibrada de aceitação no processo real: 78%. O principal risco não é a aritmética, mas a reação de revisores à ausência de validação externa e à estatística descritiva sobre partições dependentes.

Confiança nesta revisão: 92%. Foram inspecionadas as 23 páginas, o texto extraído, as 12 tabelas, as 7 figuras e os números deriváveis. Não foram verificados dados, suplemento, links, releases, scripts, matrizes completas, predições ou resultados por seed.

Cinco ações com maior efeito por custo

#	Ação	Recurso	Custo
1	Executar recomposição limpa das tabelas e publicar checksums/comando único	reanálise existente	1-3 h
2	Qualificar Nemenyi como limiar nominal descritivo já no resumo	texto	10 min
3	Trocar 'statistically detectable' por contraste condicional inconclusivo	texto	15 min
4	Padronizar 'run-to-run 95% interval' no corpo	texto	15-30 min
5	Remover 'VOLUME 11, 2023' e completar a verificação editorial do template	formatação	15 min

Nota de validade: este parecer é uma simulação editorial técnica baseada exclusivamente no manuscrito fornecido. A decisão real depende do editor, dos revisores, dos artefatos submetidos e das políticas vigentes da revista.